

Kleine Anfrage

der Abgeordneten Ruben Rupp, Robin Jünger, Alexander Arpaschi, Sebastian Maack, Tobias Ebenberger, Lars Haise, Edgar Naujok, Steffen Janich, Dr. Michael Kaufmann und der Fraktion der AfD

Zum Vorhaben eines quelloffenen europäischen Sprachmodells

Die Veröffentlichung der KI-Software (KI = Künstliche Intelligenz; engl.: AI) ChatGPT des Unternehmens OpenAI im November 2022 teilt die Evolution der Künstlichen Intelligenz in ein Davor und ein Danach. Erstmals in der Geschichte dieser Technologie wird plastisch für jedermann greifbar, wozu Künstliche Intelligenz heute imstande ist. Mit Künstlicher Intelligenz ist es auch für technische Laien möglich, Texte aller Art zu generieren, Bilder, Videos und Audiodateien anzufertigen und sich in eine ausführliche Konversation über gesellschaftliche und private Themen zu begeben. Dabei kommuniziert das Programm humanoid – es ist allein aus den Antworten oft nicht mehr ersichtlich, dass sie von einer Software kommen und nicht von einem Menschen. Die human anmutende Sprachdarstellung wird von Large Language Models (LLM), also großen Sprachmodellen, ermöglicht. Hinzu kommen multimodale Modelle, die parallel mit verschiedenen Informationsarten umgehen können, etwa Texten und Bildern.

ChatGPT und vergleichbare KI-Lösungen wie Gemini, Grok, Claude, Llama, und DeepSeek werden mit großen Datenmengen, deren Herkunft, Tiefe und Struktur nicht direkt nachvollziehbar sind, auf ihren Praxiseinsatz hin trainiert. Zudem stammen die genannten LLM von großen Konzernen, die diese Produkte in ihre Wertschöpfungsketten integrieren und damit bereits vorhandene Nutzer weiter an sich binden. Dergestalt droht sich auf dem Gebiet der Künstlichen Intelligenz die globale Dominanz einiger weniger außereuropäischer Unternehmen, die bereits das Feld der Digitalisierung bestimmen, zu wiederholen. Vor dem Hintergrund einer anzustrebenden digitalen Souveränität für Deutschland ist dies nach Auffassung der Fragesteller als kritisch zu bewerten. Nicht zuletzt kommen fast alle großen Sprachmodelle aus den USA, was dazu führt, dass weniger weit verbreitete Sprachen neben Englisch nicht so filigran und detailliert repräsentiert werden.

Zum 1. Februar 2025 hat die Europäische Kommission das Projekt OpenEuroLLM (<https://openeurollm.eu/>) lanciert, das alle Amtssprachen der EU abdecken, die Einhaltung des AI Acts der EU gewährleisten und bei Unternehmen, Entwicklern sowie Endnutzern Akzeptanz finden soll (https://strategic-technologies.europa.eu/step-results/step-stories/openeurollm-european-family-large-language-models_en?prefLang=de&etrans=de). Das Projekt nutzt die Hochleistungsrecheninfrastruktur EuroHPC, verwendet Daten europäischer Herkunft zum Training und legt den Quellcode des Programms offen (www.heise.de/news/Sprachmodell-OpenEuroLLM-soll-KI-in-der-EU-unabhaengiger-und-vielfaeltiger-machen-10269667.html).

An diesem Konsortium sind insgesamt neun Länder aus der EU beteiligt. Aus Deutschland sind die Eberhard-Karls-Universität Tübingen, das Forschungszentrum Jülich, die Fraunhofer Gesellschaft zur Förderung der angewandten Forschung sowie die Unternehmen Aleph Alpha und Ellamind involviert. Die Bundesregierung zeigt sich prinzipiell offen für die Entwicklung offener europäischer Plattformmodelle (www.koalitionsvertrag2025.de/sites/www.koalition_svertrag2025.de/files/koav_2025.pdf, hier S. 71).

Wir fragen die Bundesregierung:

1. Welche Erkenntnisse liegen der Bundesregierung rund ein Jahr nach dem Start des Projekts OpenEuroLLM über dessen gegenwärtigen Stand ggf. vor, und wann ist nach Kenntnis der Bundesregierung mit der Veröffentlichung eines ersten großen Sprachmodells im Rahmen des Projekts zu rechnen?
2. Gibt es nach Kenntnis der Bundesregierung bereits erste Pilotprojekte, mit denen die zu entwickelnden offenen europäischen Sprachmodelle getestet werden können, und wenn ja, welche Projekte existieren (bitte auflisten)?
3. Sind nach Einschätzung der Bundesregierung die veranschlagten 20,65 Mio. Euro der EU (vgl. https://strategic-technologies.europa.eu/step-results/step-stories/openeurollm-european-family-large-language-models_en?prefLang=de&ettrans=de) ausreichend, um ein wettbewerbsfähiges großes Sprachmodell zu entwickeln, und werden nach Einschätzung der Bundesregierung mit dieser Summe lediglich die Entwicklungskosten eines großen Sprachmodells abgedeckt oder auch zusätzlich die Kosten zum Training der Modelle (siehe Vorbemerkung der Fragesteller; bitte ausführen)?
4. Ist die Bundesregierung direkt finanziell am Projekt OpenEuroLLM beteiligt (siehe Vorbemerkung der Fragesteller; bitte ausführen), wenn ja, in welcher Höhe und über welchen Einzelplan des Bundeshaushalts, und wenn nein, plant die Bundesregierung künftig eine finanzielle Beteiligung am Projekt OpenEuroLLM, die über die indirekte Förderung über die EU hinausgeht?
5. Welche deutschen Hoch- und Höchstleistungsrechner sind nach Kenntnis der Bundesregierung Teil der Recheninfrastruktur, auf der die zu schaffenden großen Sprachmodelle des Projekts OpenEuroLLM trainiert werden?
6. Welche Herausforderungen erkennt die Bundesregierung ggf. bei der Bereitstellung ausreichender Rechenleistung für das multilinguale Training der Sprachmodelle des Projekts OpenEuroLLM, und wie stellen sich diese Herausforderungen dar, verglichen mit der Recheninfrastruktur, auf die Anbieter proprietärer Sprachmodelle zurückgreifen können?
7. Welche Maßnahmen plant die Bundesregierung ggf., um deutschen Start-ups, kleinen und mittleren Unternehmen (KMU), Behörden und Forschungsinstituten den Zugang zu Rechenressourcen im Rahmen von OpenEuroLLM zu erleichtern?
8. Aus welchen Quellen stammen nach Kenntnis der Bundesregierung die digitalen Daten, mit denen die zu entwickelnden Sprachmodelle des Projekts OpenEuroLLM trainiert werden, und werden dabei personenbezogene Daten, soweit sie in den Quellen vorkommen, pseudoanonymisiert oder gar anonymisiert (siehe Vorbemerkung der Fragesteller)?

9. Wie wird nach Kenntnis der Bundesregierung sichergestellt, dass die Trainingsdaten für das Projekt OpenEuroLLM datenschutzkonform beschafft und verarbeitet werden, insbesondere bei der Integration sensibler Daten aus EU-Sprachräumen mit vergleichsweise wenigen aktiven Sprechern und geringen finanziellen Ressourcen (bitte ausführen)?
10. Existieren nationale Initiativen oder nach Kenntnis der Bundesregierung Kooperationen mit Bibliotheken, Stiftungen und Archiven, um Trainingsdaten für das Projekt OpenEuroLLM bereitzustellen, und wenn ja, wie wird nach Kenntnis der Bundesregierung sichergestellt, dass solche Datensätze urheberrechtskonform verarbeitet werden (bitte ausführen)?
11. Plant die Bundesregierung eine nationale Adoptionsstrategie, um ein quelloffenes Sprachmodell des Projekts OpenEuroLLM in der öffentlichen Verwaltung, etwa als Chatbot, zu etablieren und so den Wettbewerb mit proprietären Anbietern zu stärken (bitte ausführen)?
12. Hat sich die Bundesregierung mit den Erfolgsaussichten des Projekts OpenEuroLLM im Wettbewerb mit proprietären Modellen, insbesondere hinsichtlich Leistung und Marktakzeptanz, beschäftigt und sich ggf. dazu eine eigene Positionierung erarbeitet (wenn ja, bitte ausführen), und was wären nach Einschätzung der Bundesregierung ggf. geeignete Kriterien, um die Leistung und Marktakzeptanz eines quelloffenen Sprachmodells zu messen (bitte ausführen)?
13. Welche Kriterien werden nach Kenntnis der Bundesregierung bei der Vergabe von Fördermitteln an deutsche Mitglieder im OpenEuroLLM-Konsortium angelegt, und wie wird der effiziente Einsatz dieser Mittel sichergestellt (bitte ausführen)?
14. Wie wirkt sich nach Kenntnis der Bundesregierung die Finanzierung des Projektes OpenEuroLLM auf andere nationale KI-Projekte aus?

Berlin, den 30. Januar 2026

Dr. Alice Weidel, Tino Chrupalla und Fraktion

